

性能压测规范

技术规范文件

保险公司 技术开发部
内部文档 · 仅供授权人员查阅

目录

- 1. 概述
 - 1.1 目的
 - 1.2 适用范围
- 2. 压测分类与频率
- 3. 性能指标定义
 - 3.1 通用指标
 - 3.2 保险核心系统指标参考
 - 3.3 资源指标参考
- 4. 压测场景设计
 - 4.1 场景模板
 - 4.2 必压场景清单
- 5. 压测执行流程
 - 5.1 准备阶段
 - 5.2 执行阶段
 - 5.3 压测停止条件
- 6. 结果分析与报告
 - 6.1 报告模板
- 测试概要
- 核心指标汇总
- 资源使用情况
- 瓶颈与优化建议
- 容量预估
 - 6.2 通过/不通过判定
- 7. 附录
 - 7.1 参考文档
 - 7.2 工具推荐

性能压测规范

> 参考：阿里云 PTS 最佳实践、腾讯全链路压测方案、Google 容量规划实践、JMeter 官方指南

1. 概述

1.1 目的

规范保险核心系统的性能压测流程，确保系统在承保高峰期、促销活动等大流量场景下稳定运行，满足业务 SLA 要求。

1.2 适用范围

适用于技术开发区所有需要上线的新系统、大版本迭代、以及定期的容量评估压测。

2. 压测分类与频率

压测类型	触发条件	执行频率
常规压测	大版本发布、架构调整	每个大版本前
峰值压测	承保高峰期前（如开门红、车险到期季）	高峰前 1 个月
容量评估	常规容量规划、业务量增长超预期	每季度一次
稳定性压测	长时间运行验证	大版本前
异常压测	容灾演练、混沌工程	每半年一次

3. 性能指标定义

3.1 通用指标

指标	定义	目标值参考
TPS / QPS	每秒事务/请求数	见 3.2 节
RT（响应时间）	请求从发起到响应的时间	P50 < 500ms, P99 < 2000ms
错误率	失败请求占比	< 0.1%（核心接口）
并发用户数	同时在线操作的用户数	按业务场景预估
吞吐量（MB/s）	网络/磁盘吞吐	不超过带宽的 60%

3.2 保险核心系统指标参考

业务场景	预估峰值 QPS	目标 P99 RT	数据来源
在线投保	500	< 1000ms	开门红期间峰值
保单查询	2000	< 500ms	代理人 APP 高峰
理赔报案	100	< 2000ms	灾害事件后
支付回调	300	< 1000ms	续期扣费日
续期批处理	5000（批处理）	< 30min（全量）	续期扣费批次

3.3 资源指标参考

资源	安全水位	告警水位	危险水位
CPU	< 50%	50%-70%	> 70%
内存	< 60%	60%-80%	> 80%
磁盘 IO	< 40%	40%-70%	> 70%
网络带宽	< 40%	40%-60%	> 60%
数据库连接	< 60%	60%-80%	> 80%
GC 频率	—	每分钟超过 5 次 FGC	FGC 导致暂停 > 1s

4. 压测场景设计

4.1 场景模板

```
# 压测 [压测目标]
# 压测 [压测目标]
# 压测
threads:
initial: 10 # 并发
ramp_up: 30 #  ramp up 时间
peak: 200 # 并发
duration: 300 # 压测时间
# 压测
endpoints:
- name: "压测"
url: "/v1/underwriting/evaluate"
method: POST
weight: 40 # 压测权重
data: # 压测数据
source: "proposal_data.csv"
strategy: "random"
- name: "压测"
url: "/v1/policy/{policy_no}"
method: GET
weight: 60
data:
source: "policy_no_list.csv"
strategy: "sequential"
# 断言
assertions:
- response_time_p99_lt: 2000
- error_rate_lt: 0.001
```

4.2 必压场景清单

序号	场景	说明	峰值 QPS 预估
1	投保提交 → 核保 → 出单	核心链路	500
2	保单查询（按号/按客户）	高频查询	2000
3	理赔报案 + 材料上传	文件上传场景	100
4	支付回调处理	外部系统回调	300

序号	场景	说明	峰值 QPS 预估
5	续期批量扣费	批处理场景	5000（批处理）
6	保全变更 + 重新计算	写操作场景	200
7	登录 + 权限校验	混合场景基础	800
8	数据报表查询	复杂查询场景	50

5. 压测执行流程

5.1 准备阶段

- [] 确定压测目标（性能基准 vs 容量极限 vs 稳定性）
- [] 搭建压测环境（与生产环境配置等比或按比例）
- [] 准备测试数据（满足场景覆盖，数据量接近生产规模）
- [] 部署监控（APM / Prometheus / Grafana）
- [] 编写压测脚本
- [] 执行冒烟测试（验证脚本可用性）

5.2 执行阶段

1. 基准测试：单接口、低并发（1-5 线程），确定基线 RT
2. 负载测试：逐步增加并发，观察性能拐点
3. 峰值测试：使用目标峰值压力持续运行 30 分钟
4. 稳定性测试：70% 峰值压力持续运行 4-8 小时
5. 极限测试：持续增加压力直至系统崩溃或达到瓶颈

5.3 压测停止条件

- 错误率超过 5% 且持续增长
- 核心接口 P99 RT 超过目标值的 3 倍
- CPU / 内存持续超过危险水位
- 数据库主从延迟超过 30 秒
- 监控发现关键服务已熔断/降级

6. 结果分析与报告

6.1 报告模板

```
# 测试脚本名称 [脚本名] v[版本]
## 测试信息
- 测试日期 YYYY-MM-DD
- 测试环境 [环境]
- 测试人员 [姓名]
## 测试结果
| 接口 | 并发 QPS | 线程 QPS | 平均 P99 | 峰值 P99 | 错误率 | 耗时 |
| --- | --- | --- | --- | --- | --- | --- |
| 接口1 | 500 | 520 | 1000ms | 850ms | 0.01% | 10 |
| 接口2 | 2000 | 2100 | 500ms | 320ms | 0% | 10 |
## 系统资源
| 指标 | CPU | 内存 | GC | 磁盘 |
```

```
| --- | --- | --- | --- | --- |
| policy-service | 45% | 3.2G/8G | FGC: 0 | 00 |
| underwriting-service | 52% | 4.1G/8G | FGC: 1 | 00 |
## 00000000
1. [0000] → [0000]
2. [0000] → [0000]
## 0000
- 00000000[X] QPS
- 00 6 00000000[Y] QPS
- 00000 [0000]
```

6.2 通过/不通过判定

判定	条件
通过	所有核心场景达到目标 QPS 且 P99 RT 和错误率在阈值内
有条件通过	非核心场景未达目标，但有明确的优化计划
不通过	核心场景未达目标，或存在性能瓶颈可能导致生产故障

7. 附录

7.1 参考文档

- JMeter 官方文档
- 《全链路压测实施指南》
- 《上线Checklist规范》
- Google SRE 容量规划章节

7.2 工具推荐

用途	推荐工具	备选
压测工具	JMeter / k6	Gatling / Locust
全链路压测	阿里云 PTS	腾讯 WeTest
APM	SkyWalking / Pinpoint	Datadog
监控	Prometheus + Grafana	Zabbix
链路追踪	Jaeger	Zipkin
混沌工程	ChaosBlade	Litmus