

数据架构规范

技术规范文件

保险公司 技术开发部
内部文档 · 仅供授权人员查阅

目录

- 1. 概述
- 2. 数据架构原则
- 3. 数据分层规范
- 4. 数据模型设计规范
 - 4.1 模型分层设计
 - 4.2 核心数据模型举例
- 5. 数据存储选型
- 6. 数据流转规范
 - 6.1 实时同步链路
 - 6.2 离线同步链路
- 7. 数据治理规范
- 8. 监管报送数据规范

数据架构规范

1. 概述

本文档定义保险公司数据架构的总体规范，包括数据分层、数据建模、数据存储选型、数据流转、数据治理等内容。参考阿里巴巴数据中台方法论、蚂蚁集团数据治理实践。

2. 数据架构原则

1. 统一标准：全域数据遵循统一命名、类型、编码规范
2. 分层解耦：数据按 ODS → DWD → DWS → ADS 分层，每一层职责明确
3. 数据闭环：每条数据链路具备端到端可追溯能力
4. 就近计算：尽量将计算下推到存储层或离数据最近的位置
5. 最小权限：数据访问遵循按需授权、最小够用原则

3. 数据分层规范

层级	英文	职责	存储	保留周期
ODS	Operational Data Store	源系统数据全量接入	HDFS / Kafka	30天
DWD	Data Warehouse Detail	清洗后明细数据，业务事实+维度	Hive / Iceberg	按监管要求
DWS	Data Warehouse Summary	轻度汇总，业务主题宽表	ClickHouse	按监管要求
ADS	Application Data Store	应用级数据集市	MySQL / ClickHouse	按业务需求
DIM	Dimension	公共维度数据	MySQL / Redis	长期保留
STG	Staging	临时中间结果	HDFS / OSS	T+7后清理

4. 数据模型设计规范

4.1 模型分层设计

ODS 层

- 表结构 1:1 映射源系统
- 增量/全量两种同步方式
- 保留原始数据，不做清洗或合并

DWD 层

- 遵循 3NF 或 Data Vault 模型
- 字段进行标准化（统一编码、日期格式）
- 保持明细粒度，不做预聚合

DWS 层

- 按主题组织（承保主题、理赔主题、客户主题）
- 轻度聚合，减少查询扫描量
- 宽表设计，常用维度退化到事实表

ADS 层

- 面向具体应用场景（监管报表、经营分析、风控模型）
- 可根据性能需要做适度冗余
- 大宽表或星型模型

4.2 核心数据模型举例

保单事实表 DWD（承保主题）

```
CREATE TABLE dwd_policy_fact (  
  policy_id STRING COMMENT '保单ID',  
  application_id STRING COMMENT '应用ID',  
  product_code STRING COMMENT '产品代码',  
  channel_code STRING COMMENT '渠道代码',  
  applicant_id STRING COMMENT '申请人ID',  
  insured_id STRING COMMENT '被保险人ID',  
  premium_amount DECIMAL(18,2) COMMENT '保费金额',  
  sum_insured DECIMAL(18,2) COMMENT '保额',  
  policy_status STRING COMMENT '保单状态',  
  effective_date DATE COMMENT '生效日期',  
  expire_date DATE COMMENT '到期日期',  
  uw_result STRING COMMENT '核保结果',  
  issue_datetime TIMESTAMP COMMENT '出单时间',  
  etl_time TIMESTAMP COMMENT 'ETL时间'  
) PARTITIONED BY (dt STRING)  
STORED AS PARQUET;
```

5. 数据存储选型

数据类型	存储引擎	适用场景
在线事务(OLTP)	MySQL 8.0 / PolarDB	核心业务数据
缓存	Redis Cluster	热数据、会话、计数器
搜索引擎	Elasticsearch	保单全文检索、日志
时序数据	Prometheus / VictoriaMetrics	监控指标
离线分析	Spark + Hive/Iceberg	ETL、数仓
实时分析	Flink + ClickHouse	实时报表、大屏
对象存储	MinIO / OSS / S3	影像、文件
消息队列	RocketMQ / Kafka	异步事件、流处理

6. 数据流转规范

6.1 实时同步链路

MySQL(Binlog) → Canal → Kafka → Flink → ClickHouse / Redis

- 适用场景：保单状态实时更新、实时风控、实时大屏
- 一致性要求：至少一次投递，业务侧做幂等

6.2 离线同步链路

MySQL(Sqoop/DataX) → HDFS → Hive(ODS) → Spark(DWD/DWS) → ClickHouse(ADS)

- 适用场景：监管报送、经营分析、精算定价

7. 数据治理规范

治理领域	规范要求	工具
数据质量	非空率、唯一性、格式合规自动化监控	Great Expectations / Deequ
数据血缘	字段级血缘自动追踪	Atlas / DataHub
元数据管理	表结构、字段注释、变更历史	自研元数据平台
数据安全	敏感数据自动发现 + 脱敏 + 加密	数据安全平台
生命周期	冷热数据自动分层，过期自动清理	生命周期管理策略

8. 监管报送数据规范

- 监管报送数据单独从 ODS/DWD 层加工，不经过 ADS 层
- 所有报送数据保留至少 7 年
- 每次报送前需要核对产出数据与源系统数据的一致性
- 报送接口只增不删，历史报送接口需保留兼容